

Previsão Antecipada do Tempo de Internamento na UCI

Pipeline de Engenharia de Dados e Machine Learning no MIMIC-III

Beatriz Seabra · Iara Ferreira

Faculdade de Ciências da Universidade do Porto (FCUP)

Dataset: MIMIC-III (Medical Information Mart for Intensive Care)

Índice

1. Introdução e Contextualização do Problema

2. Fase 1 : Arquitetura, Extração, Limpeza e Preparação dos Dados

- 2.1 Arquitetura de Dados e Tabelas Seleccionadas
- 2.2 Validação Inicial de Estrutura
- 2.3 Seleção Clínica de Sinais Vitais via D_ITEMS
- 2.4 Cruzamento Relacional e JOIN Triplo
- 2.5 Limpeza de Dados e Feature Engineering
- 2.6 Análise Exploratória de Dados (EDA)
- 2.7 Análise Comparativa de Janelas Temporais
- 2.8 Construção da Feature Matrix
- 2.9 Encerramento e Checkpoint da Fase 1

3. Fase 2 : Pré-processamento, Modelação e Validação

- 3.1 Validação Estrutural e Definição de Features
- 3.2 Split Treino/Teste por Paciente
- 3.3 Pipeline de Pré-processamento
- 3.4 Modelos Lineares : Baseline Supervisionado
- 3.5 Modelos Baseados em Árvores e Gradient Boosting
- 3.6 Validação Cruzada com GroupKFold
- 3.7 Ajustação de Hiperparâmetros
- 3.8 Avaliação Final e Análise dos Erros
- 3.9 Interpretabilidade com Permutation Importance
- 3.10 Análise de Sensibilidade e Conclusão da Fase 2

4. Fase 3 : Estratificação de Risco por Janelas Temporais

- 4.1 Motivação e Objetivos
- 4.2 Criação das Matrizes por Janela Temporal
- 4.3 Targets Binários de Estadia Prolongada
- 4.4 Treino Inicial dos Modelos de Classificação
- 4.5 Comparação Global entre Janelas Temporais
- 4.6 Ajustação de Threshold e Avaliação Final
- 4.7 Interpretabilidade e Análise de Risco
- 4.8 Comparação com a Regressão da Fase 2
- 4.9 Precocidade vs. Desempenho - Discussão Final
- 4.10 Profiling Computacional e Discussão de Performance

5. Conclusão Geral

6. Referências

1. Introdução e Contextualização do Problema

O **MIMIC-III** (Medical Information Mart for Intensive Care) é uma base de dados relacional de acesso aberto que contém dados clínicos anonimizados de doentes internados em Unidades de Cuidados Intensivos (UCI) do Beth Israel Deaconess Medical Center, nos EUA. A sua estrutura abrange múltiplas tabelas interligadas por identificadores como **SUBJECT_ID**, **HADM_ID**, **ICUSTAY_ID** e **ITEMID**, permitindo cruzar informação clínica longitudinal com dados administrativos e demográficos.

O objetivo central deste projeto é a previsão antecipada do tempo de internamento na UCI (Length of Stay: LOS), expresso em dias. A previsão antecipada do LOS tem um impacto direto na gestão hospitalar: permite otimizar a alocação de recursos, antecipar altas e transferências, e identificar doentes em risco de internamento prolongado ainda nas primeiras horas de estadia.

O projeto está organizado em três fases complementares:

Fase	Tipo de Tarefa	Descrição
Fase 1	Engenharia de Dados	Extração, limpeza, EDA e construção da feature matrix
Fase 2	Regressão (ML)	Previsão direta do LOS em dias com melhores modelos obtidos
Fase 3	Classificação (ML)	Estratificação de risco de estadia prolongada por janelas temporais

A infraestrutura tecnológica utilizada assenta em Google Cloud Platform (BigQuery + GCS) para o processamento de dados de grande escala, Google Colab para o desenvolvimento dos notebooks, e um stack de bibliotecas Python (pandas, scikit-learn, LightGBM, XGBoost, SHAP) para modelação e interpretabilidade.

2. Fase 1: Arquitetura, Extração, Limpeza e Preparação dos Dados

2.1 Arquitetura de Dados e Tabelas Seleccionadas

O MIMIC-III é composto por múltiplas tabelas clínicas, administrativas e de dicionário. A seleção das tabelas a incluir no pipeline foi guiada por três critérios:

- Disponibilidade temporal: apenas variáveis disponíveis no momento da admissão ou nas primeiras horas de internamento, evitando data leakage futuro.
- Comparabilidade entre estadias: preferência por variáveis estruturadas e fisiológicas com boa cobertura na amostra.
- Eficiência computacional: dado o volume de CHARTEVENTS (>330M registos), a filtragem foi feita diretamente no BigQuery antes da extração para pandas.

Tabela	Descrição	Dimensão Esperada	Papel no Pipeline
CHARTEVENTS	Biometria contínua da UCI	>330M linhas	Fonte principal dos sinais clínicos
PATIENTS	Dados demográficos	~46k linhas	Idade e género
ADMISSIONS	Histórico de internamentos	~58k linhas	Contexto administrativo
ICUSTAYS	Estadias na UCI	~61k linhas	Variável-alvo (LOS)
D_ITEMS	Dicionário de ITEMIDs	~12k linhas	Tradução semântica dos sinais
INPUTEVENTS_MV	Fluidos e terapêutica	~3.6M linhas	Eventos de input clínico

Nota

A tabela ADMISSIONS foi excluída do JOIN principal por não ser necessária para a variável-alvo, já disponível em ICUSTAYS. D_ITEMS foi usada apenas na fase de validação semântica, e não na query principal de extração.

2.2 Validação Inicial de Estrutura (Sanity Check)

Antes de avançar para as agregações relacionais, foi realizada uma validação técnica inicial às 6 tabelas. Esta etapa confirma a conectividade com o BigQuery, a disponibilidade das tabelas e a integridade estrutural dos dados.

Destaca-se a observação de datas projetadas para anos futuros (2104-2210), resultante do processo de anonimização temporal do MIMIC-III para proteção da identidade dos doentes. Esta característica não afeta os intervalos temporais entre eventos, que são matematicamente preservados.

A análise de nulos confirmou boa completude estrutural nas tabelas principais: sem nulos em campos críticos de PATIENTS e ADMISSIONS, e apenas 10 registos com LOS ausente em ICUSTAYS (numa população de 61 532 estadias).

Tabela	Colunas Críticas avaliadas	Total de registos	Nulos encontrados	Observações
ADMISSIONS	HADM_ID	58 976	0	Sem nulos na chave hospitalar
D_ITEMS	LABEL	12 487	0	Apenas 3 labels em falta
PATIENTS	GENDER, DOB	46 520	0	Dados demográficos completos
ICUSTAYS	INTIME, LOS	61 532	10 em LOS	Impacto residual
INPUTEVENTS_MV	AMOUNT, ICUSTAY_ID	3 618 991	1 em ICUSTAY_ID 164	Pequena proporção face ao total
INPUTEVENTS_MV	Fluidos e terapêutica	330 712 483	Eventos de input clínico	Esperado devido ao volume e natureza da tabela

Conclusões e observações da tabela :

A análise de nulos mostrou que as tabelas estruturais principais apresentavam boa qualidade para o desenvolvimento do pipeline. As tabelas 'ADMISSIONS' e 'PATIENTS' não apresentaram nulos nas colunas críticas avaliadas, enquanto a tabela 'ICUSTAYS' apresentou apenas 10 valores em falta na variável 'LOS', um valor residual face ao total de 61 532 estadias.

Na tabela 'CHARTEVENTS', foram identificados valores nulos em 'VALUE' e 'ICUSTAY_ID'. No entanto, esta tabela contém mais de 330 milhões de registos, pelo que estes valores representam uma fração reduzida do volume total. Além disso, na etapa seguinte do pipeline foram considerados apenas registos com 'ICUSTAY_ID' e valores clínicos numéricos válidos, garantindo que as medições usadas na construção da feature matrix tinham qualidade suficiente.

Assim, o sanity check confirmou que as tabelas estavam acessíveis, tinham dimensões coerentes com o esperado e apresentavam completude suficiente para avançar para a seleção dos sinais clínicos e para o JOIN principal no BigQuery.

2.3 Seleção Clínica de Sinais Vitais via D_ITEMS

A tabela CHARTEVENTS regista observações clínicas através de identificadores numéricos (ITEMID). Para garantir uma seleção rigorosa e clinicamente justificada, foi primeiro analisada a frequência absoluta dos ITEMIDs, permitindo identificar as variáveis mais representadas.

A análise mostrou que uma seleção baseada apenas na frequência não seria adequada: alguns ITEMIDs muito frequentes correspondem a metadados administrativos ou anotações logísticas. Além disso, o MIMIC-III integra

dados de dois sistemas (CareVue e MetaVision), pelo que o mesmo sinal clínico pode surgir com diferentes ITEMIDs.

Top 15 ITEMIDs mais frequentes em CHARTEVENTS

ITEMID	LABEL	Ocorrências
211	Heart Rate	5 180 809
742	calprevflg	3 464 326
646	SpO2	3 418 917
618	Respiratory Rate	3 386 719
212	Heart Rhythm	3 303 151
161	Ectopy Type	3 236 350
128	Code Status	3 216 866
550	Precautions	3 205 052
1125	Service Type	2 955 851
220045	Heart Rate	2 762 225
220210	Respiratory Rate	2 737 105
220277	O2 saturation pulseoxymetry	2 671 816
159	Ectopy Frequency	2 544 519
1484	Risk for Falls	2 261 065
51	Arterial BP [Systolic]	2 096 678

Conclusões e observações da tabela :

A análise dos 15 ITEMIDs mais frequentes em 'CHARTEVENTS' mostrou que a frequência absoluta, por si só, não é um critério suficiente para selecionar variáveis clínicas. Embora alguns dos ITEMIDs mais frequentes correspondam a sinais vitais relevantes, como 'Heart Rate', 'SpO2', 'Respiratory Rate' e pressão arterial sistólica, outros representam metadados administrativos, estados logísticos ou informações não diretamente adequadas para modelação clínica, como 'calprevflg', 'Code Status', 'Precautions', 'Service Type' e 'Risk for Falls'.

Esta observação justificou a necessidade de uma seleção clínica manual e validada através da tabela 'D_ITEMS', em vez de uma seleção automática baseada apenas na frequência. Além disso, a presença de sinais repetidos com diferentes ITEMIDs, como 'Heart Rate' nos ITEMIDs 211 e 220045, confirma a coexistência dos sistemas CareVue e MetaVision no MIMIC-III. Por essa razão, foi necessário harmonizar os ITEMIDs equivalentes para representar corretamente cada sinal clínico.

Dicionário de sinais vitais encontrados :

Foram selecionados 11 sinais clínicos referenciados no sistema SOFA, abrangendo 18 ITEMIDs distribuídos pelos sistemas CareVue e MetaVision:

Sinal Clínico	ITEMIDs (CareVue / MetaVision)	Unidade	Intervalo Fisiológico
Heart Rate	211, 220045	bpm	1 - 300
SBP (Systolic BP)	51, 220179	mmHg	1 - 375
DBP (Diastolic BP)	8368, 220180	mmHg	1 - 375
MBP (Mean BP)	52, 220052	mmHg	1 - 375
Respiratory Rate	618, 220210	insp/min	1 - 70
Temperature	223761, 678, 676, 223762	°C / °F	14.2 - 47.2 (°C)
SpO2	646, 220277	%	0 - 100
GCS Total	198, 220739	score	3 - 15
GCS Eye Opening	184, 220739	score	1 - 4
GCS Motor Response	454, 223901	score	1 - 6
GCS Verbal Response	723, 223900	score	1 - 5

Conclusão

Os ITEMIDs associados a scores APACHE foram explicitamente excluídos por serem variáveis derivadas e não observações clínicas brutas. Todos os 18 ITEMIDs foram validados na tabela D_ITEMS antes de serem usados na query principal.

2.4 Cruzamento Relacional: JOIN Triplo no BigQuery

A query central do pipeline integra três tabelas (CHARTEVENTS, PATIENTS e ICUSTAYS) numa única operação SQL executada diretamente no BigQuery. Esta abordagem evita erros de Out of Memory no Colab e reduz drasticamente o volume de dados transferidos.

Decisões arquiteturais relevantes do JOIN:

- INTIME foi usada como referência temporal principal (em vez de ADMITTIME), garantindo alinhamento com a unidade de análise - a estadia na UCI - e evitando data leakage.
- A filtragem por ITEMID foi realizada dentro do BigQuery, reduzindo os >330M de registos de CHARTEVENTS para os eventos clinicamente relevantes.
- Apenas registos com ICUSTAY_ID e VALUENUM não nulos foram extraídos, garantindo a qualidade dos dados de entrada.

Métrica	Valor
Total de registos extraídos	16 608 803
Estadias UCI únicas	59 137
Pacientes únicos	44 985

2.5 Limpeza de Dados e Feature Engineering


Normalização temporal e cálculo da idade

Todas as colunas temporais (DOB, INTIME, OUTTIME, CHARTTIME) foram convertidas para datetime sem metadados de fuso horário (UTC normalizado), permitindo operações aritméticas consistentes.

A idade foi calculada com precisão cronológica (dia e mês) a partir de INTIME. Foram aplicadas as seguintes correções:

- Correção HIPAA: doentes com idade ≥ 89 anos têm a data de nascimento deslocada no MIMIC-III; estes registos foram imputados para 90 anos (789 972 linhas corrigidas).
- Salvaguarda neonatal: idade mínima protegida para casos pediátricos.

Distribuição da Idade antes e depois da correção HIPAA



Conclusões e observações do gráfico:

A comparação entre as duas distribuições confirma a importância da correção da idade antes da construção da matriz final. Na distribuição original, observa-se um pico artificial próximo dos 300 anos, que não corresponde a idades reais, mas sim ao processo de anonimização do MIMIC-III aplicado a pacientes com idade superior a 89 anos.

Após a correção, estes registos foram recodificados para 90 anos, eliminando o artefacto extremo sem remover os pacientes da análise. Esta decisão preserva a informação clínica relevante associada à idade avançada, mas evita que valores impossíveis distorçam estatísticas descritivas, gráficos e futuras etapas de modelação.

No total, foram corrigidas 789 972 linhas com idade superior a 89 anos. Este número refere-se ao número de medições/registos na base extraída, e não ao número de pacientes únicos, uma vez que cada paciente pode ter várias medições clínicas associadas.


Validação do LOS e Remoção de Outliers Fisiológicos

O LOS foi recalculado a partir de OUTTIME – INTIME e comparado com o valor original do MIMIC-III. O coeficiente de correlação de Pearson confirmou a consistência ($r \approx 1.000000$), validando que a normalização temporal não introduziu erros.

A limpeza fisiológica removeu 35 886 registos (0.2161% da base extraída) com base nos limites definidos no dicionário de sinais vitais. Esta percentagem reduzida indica que os filtros atuaram sobretudo sobre artefactos extremos.

Distribuição dos Sinais Clínicos Antes e Depois da Limpeza Fisiológica

Distribuição das 11 Variáveis Clínicas Seleccionadas (Pós-Limpeza Fisiológica)



Conclusões e observações do gráfico:

A análise visual confirma que, após a aplicação dos limites fisiológicos, os 11 sinais clínicos seleccionados apresentam distribuições coerentes e compatíveis com valores clinicamente plausíveis. As variáveis cardiovasculares e respiratórias, como 'Heart Rate', 'SBP', 'DBP', 'MBP', 'SpO2' e 'Respiratory Rate', concentram-se em intervalos esperados para uma população na UCI, mantendo ainda alguma variabilidade clínica relevante.

Observa-se também que nem todos os sinais têm a mesma frequência de registo. Variáveis monitorizadas de forma mais contínua, como 'Heart Rate', 'SpO2' e 'Respiratory Rate', apresentam maior volume de medições, enquanto variáveis como 'Temperature' e as componentes do 'GCS' surgem com menor frequência. Esta diferença é esperada em contexto de cuidados intensivos, onde alguns sinais são medidos continuamente e outros apenas em momentos clínicos específicos.

As variáveis associadas ao Glasgow Coma Scale apresentam distribuições discretas, como seria esperado por se tratarem de scores ordinais. A concentração em valores superiores indica que muitos doentes apresentam estado neurológico relativamente preservado, mas a presença de valores mais baixos mostra que a base mantém também casos clinicamente mais graves.

Assim, este gráfico valida que a limpeza fisiológica removeu artefactos extremos sem eliminar a variabilidade clínica necessária para a modelação. A base resultante é, portanto, coerente e adequada para a construção da feature matrix nas etapas seguintes.

2.6 Análise Exploratória de Dados (EDA)


Distribuição da Variável-Alvo LOS_DIAS

A distribuição do LOS_DIAS, calculada sobre 59 135 estadias UCI únicas, apresenta forte assimetria à direita:

Estatística	Valor
Mínimo	~0.00 dias
Mediana	2.14 dias
Média	5.01 dias
Percentil 90	11.03 dias
Percentil 99	47.05 dias
Skewness	6.28

Distribuição do LOS_DIAS (escala linear e logarítmica)

Variável Alvo: Length of Stay (LOS): Análise de Distribuição



Conclusões e observações do gráfico:

A distribuição do 'LOS_DIAS' apresenta uma forte assimetria positiva, com a maioria das estadias concentrada nos primeiros dias de internamento e uma cauda longa correspondente a internamentos muito prolongados. Esta

diferença é evidente pela distância entre a mediana, de aproximadamente 2.14 dias, e a média, de cerca de 5.01 dias.

A escala logarítmica permite visualizar melhor essa cauda longa, mostrando que existem poucos casos com durações muito elevadas, mas suficientemente extremos para influenciar a média e aumentar a dispersão da variável-alvo. Este comportamento é típico de dados clínicos de internamento, onde a maioria dos doentes permanece pouco tempo na UCI, mas uma fração reduzida necessita de cuidados prolongados.


Esta distribuição tem impacto direto na modelação da Fase 2. Como o 'LOS_DIAS' não segue uma distribuição simétrica, será importante usar métricas robustas como o 'MAE' e considerar também o 'RMSE', que penaliza mais os erros em estadias longas. Além disso, a forte assimetria justifica testar uma transformação logarítmica do target, como 'log1p(LOS_DIAS)', para reduzir o peso dos casos extremos.

Por fim, a elevada concentração de estadias curtas reforça a importância da escolha da janela temporal. Janelas de 48h ou 72h podem ser demasiado longas para muitos pacientes, uma vez que parte das estadias termina antes desse período. Por isso, a janela de 24h surge como uma opção mais equilibrada entre precocidade da previsão e disponibilidade de informação clínica.

LOS_DIAS por Faixa Etária e Género

A análise demográfica mostrou diferenças estatisticamente significativas no LOS entre faixas etárias (Kruskal-Wallis: $H = 288.05$, $p = 3.8401e-62$), embora de magnitude limitada na prática clínica. O teste de Mann-Whitney entre géneros não evidenciou diferenças relevantes.

LOS_DIAS por faixa etária e por género



Conclusões e observações do gráfico:

A análise demográfica mostra que o 'LOS_DIAS' varia ligeiramente entre faixas etárias. Visualmente, observa-se um aumento gradual da mediana do tempo de internamento com a idade: os pacientes mais jovens apresentam uma mediana inferior, enquanto os grupos etários mais avançados tendem a apresentar estadias ligeiramente mais longas. Apesar de a diferença ser estatisticamente significativa pelo teste de Kruskal-Wallis, a magnitude

visual da diferença é moderada, pelo que a relevância prática desta variável deverá ser avaliada posteriormente na modelação.

Na análise por género, as distribuições de 'LOS_DIAS' são muito semelhantes entre os grupos masculino e feminino. O teste de Mann-Whitney não indicou uma diferença estatisticamente significativa, sugerindo que, isoladamente, o género não apresenta uma associação relevante com o tempo de internamento na UCI.


Assim, a variável 'IDADE' parece ter algum potencial preditivo e deve ser mantida na matriz final. Já a variável 'GENDER_BIN', embora não apresente uma diferença clara nesta análise univariada, pode ser mantida inicialmente e reavaliada na Fase 2 através da importância das variáveis e do desempenho dos modelos.

Análise por Paciente (SUBJECT_ID)

A população analisada contém 44 983 pacientes únicos e 59 135 estadias UCI. A maioria dos pacientes (36 697) tem apenas uma estadia na UCI, mas existe um subconjunto com múltiplas readmissões (máximo: 41 estadias para um mesmo paciente). Esta observação fundamenta a necessidade de separar treino e teste por SUBJECT_ID.

Distribuição do número de estadias por paciente

Análise Estatística por Paciente (SUBJECT_ID) — Heterogeneidade da Coorte



Conclusões e observações do gráfico:

A análise por paciente confirma que a coorte apresenta elevada heterogeneidade. A maioria dos pacientes tem apenas uma estadia na UCI, com 36 697 pacientes nesta situação, enquanto um subconjunto menor apresenta múltiplas readmissões. Isto mostra que, embora a unidade de análise principal seja a estadia ('ICUSTAY_ID'), existem vários pacientes com mais do que um episódio clínico registado.

A distribuição do número de registos biométricos por paciente também é bastante assimétrica. A mediana situa-se nos 281 registos por paciente, mas existem casos com volumes muito superiores de medições. Esta diferença pode resultar de estadias mais longas, maior intensidade de monitorização ou múltiplas admissões na UCI.


O gráfico das variáveis clínicas mais registadas mostra que sinais como 'Heart Rate', 'Respiratory Rate' e 'SpO2' dominam em volume de medições, refletindo a sua monitorização frequente em contexto de cuidados intensivos. Em contraste, variáveis como 'Temperature' e componentes do 'GCS' apresentam menor volume, o que é esperado por serem registadas de forma menos contínua.

Estes resultados justificam duas decisões metodológicas importantes: a matriz preditiva deve usar 'ICUSTAY_ID' como unidade de observação, pois cada estadia representa um episódio clínico distinto; no entanto, a separação entre treino e teste na Fase 2 deve ser feita por 'SUBJECT_ID', evitando que estadias diferentes do mesmo paciente apareçam simultaneamente nos dois conjuntos e provoquem data leakage.

Análise dos Eventos de Input: Estadia ICUSTAY_ID = 200072

Foi realizada uma visualização específica dos eventos de input (tabela INPUTEVENTS_MV) registados nas primeiras 24 horas da estadia ICUSTAY_ID = 200072. O eixo temporal foi representado em frações de dia (0.0 = entrada na UCI).

Eventos de Input da Estadia 200072



Conclusões e observações do gráfico:

A visualização dos eventos de input da estadia `ICUSTAY\_ID = 200072` mostra a diversidade de intervenções clínicas registadas nas primeiras 24 horas de internamento. Observam-se diferentes tipos de inputs, incluindo fluidos, eletrólitos, medicação, insulina e produtos sanguíneos, distribuídos ao longo do primeiro dia de estadia.

A maioria dos eventos ocorre de forma pontual e com quantidades relativamente baixas, mas existem alguns registos com valores mais elevados, como o caso associado ao item `D5 1/2NS`. Esta diferença evidencia a heterogeneidade da tabela `INPUTEVENTS\_MV`, onde cada linha representa uma administração clínica específica, podendo variar bastante em tipo, momento e quantidade.

Apesar de esta tabela fornecer informação clínica relevante sobre intervenções realizadas ao doente, estes eventos não foram integrados na feature matrix final da Fase 1. A matriz preditiva foi construída com base nos sinais clínicos de `CHARTEVENTS`, nos dados temporais de `ICUSTAYS` e nas variáveis demográficas de `PATIENTS`.

Assim, esta análise teve um papel essencialmente exploratório: permitiu demonstrar a natureza longitudinal dos eventos clínicos no MIMIC-III e cumprir a componente visual de análise de inputs, sem alterar a estrutura principal do pipeline usado nas fases seguintes.


2.7 Análise Comparativa de Janelas Temporais (24h / 48h / 72h)

Uma das questões metodológicas centrais da Fase 1 é a escolha da janela temporal para construção da matriz preditiva. Foram comparadas três janelas candidatas:

Janela	Estadias com Dados	Registos Totais	Mediana Sinais/Estadia	% Estadias c/ ≥ 5 Sinais	% LOS < Janela
24h	59 057	8 198 353	8	88.5%	17.99%
48h	59 115	13 278 585	~14	>88%	~8%
72h	59 135	16 572 917	~20	>88%	~4%

Trade-off entre Janelas Temporais

Trade-Off de Janela Temporal: Precocidade vs. Riqueza Informacional



Conclusões e observações do gráfico:

A comparação entre as janelas temporais evidencia o compromisso entre precocidade da previsão e quantidade de informação disponível. Em termos de cobertura, as três janelas apresentam números muito semelhantes de estadias com dados disponíveis: 59 057 em 24h, 59 115 em 48h e 59 135 em 72h. Isto mostra que a janela de 24h já permite incluir praticamente toda a população analisada.

Como esperado, a densidade informacional aumenta com o tamanho da janela. A média de registos por estadia passa de 138.8 nas primeiras 24h para 224.6 em 48h e 280.3 em 72h. No entanto, este aumento representa sobretudo mais medições dos mesmos sinais, uma vez que a percentagem de estadias com pelo menos 5 sinais clínicos se mantém estável em 88.5% nas três janelas.

O ponto mais relevante é a percentagem de estadias cujo 'LOS_DIAS' é inferior à própria janela temporal. Este valor aumenta de 18.0% em 24h para 46.2% em 48h e 62.3% em 72h. Assim, janelas mais longas aumentam o risco de a previsão ser feita demasiado tarde, quando uma parte considerável dos pacientes já teria saído da UCI.

Desta forma, a janela de 24h foi considerada a opção mais equilibrada: mantém cobertura elevada, fornece informação clínica suficiente e preserva a utilidade prática da previsão precoce. Por isso, foi escolhida para a construção da feature matrix final da Fase 1.

Conclusão


Foi selecionada a janela de 24 horas. Esta escolha equilibra precocidade clínica (previsão no primeiro dia), cobertura da população (~100%) e densidade informacional suficiente. O aumento para 48h ou 72h não justifica a perda de antecipação dada a marginal melhoria na diversidade de sinais.

Timeline de 3 Perfis Clínicos

Foram selecionadas três estadias com LOS distintos para ilustrar a evolução dos sinais clínicos nas primeiras 24h:

- Perfil A (LOS curto, ~1.9 dias): evolução estável, sem grandes oscilações.
- Perfil B (LOS médio, ~4.3 dias): maior variabilidade temporal nos sinais cardiovasculares.
- Perfil C (LOS longo, >7 dias): instabilidade clínica persistente ao longo do primeiro dia.

Timeline dos 3 Perfis Clínicos



Conclusões e observações do gráfico:

A comparação dos três perfis clínicos mostra que sinais biométricos recolhidos nas primeiras 24 horas já refletem diferenças relevantes entre estadias com durações finais distintas. No Perfil A, correspondente a um LOS curto, observa-se uma evolução globalmente mais estável dos sinais monitorizados, sem oscilações persistentes muito acentuadas ao longo do primeiro dia.

No Perfil B, com LOS intermédio, verifica-se maior variabilidade temporal, sobretudo nos sinais cardiovasculares e respiratórios, sugerindo um comportamento clínico mais dinâmico durante as primeiras 24 horas. Já no Perfil C, associado a uma estadia prolongada, observa-se maior dispersão e instabilidade inicial em vários sinais, ilustrando um quadro fisiológico potencialmente mais complexo desde cedo.

Embora esta análise tenha caráter apenas ilustrativo e não permita generalizações para toda a coorte, ela ajuda a mostrar que as primeiras 24 horas contêm informação clínica relevante para distinguir perfis de internamento diferentes. Esta observação reforça a decisão metodológica de transformar os dados longitudinais em variáveis agregadas por 'ICUSTAY_ID', utilizando estatísticas como média, mínimo, máximo, desvio-padrão e número de medições por sinal clínico.

2.8 Construção da Feature Matrix

O dataset `df_24h` (formato long, uma linha por medição) foi transformado em formato wide através de agregações estatísticas por `ICUSTAY_ID`. Cada sinal clínico foi sumarizado com 5 estatísticas: média, desvio-padrão, mínimo, máximo e contagem.

Dimensão da Matriz Final	Valor
Estadias UCI (linhas)	59 057
Total de colunas	60
Features clínicas (11 sinais × 5 stats)	55
Variáveis demográficas	IDADE, GENDER_BIN
Identificadores	ICUSTAY_ID, SUBJECT_ID
Variável-alvo	LOS_DIAS
% de valores nulos nas features	27.71%

Análise de Missing Values na Feature Matrix

A maior percentagem de nulos concentra-se nas variáveis do Glasgow Coma Scale, o que é clinicamente esperado: os registos neurológicos têm menor frequência de medição do que os sinais hemodinâmicos contínuos. A ausência de medição pode ser clinicamente informativa (doentes com registo de GCS são clinicamente diferentes dos que não o têm), justificando a utilização de indicadores de missingness na Fase 2.

Métrica	Valor
Total de células preditivas	3 366 249
Valores nulos	932 744
Percentagem de nulos	27.71%

Missing Values por Feature

Feature	% Nulos
GCS_Motor_Response_mean	60.57
GCS_Motor_Response_std	60.57
GCS_Motor_Response_min	60.57
GCS_Motor_Response_max	60.57
GCS_Verbal_Response_mean	60.56
GCS_Verbal_Response_min	60.56
GCS_Verbal_Response_max	60.56
GCS_Verbal_Response_std	60.56
GCS_Eye_Opening_mean	60.55
GCS_Eye_Opening_std	60.55
GCS_Eye_Opening_min	60.55

GCS_Eye_Opening_max	60.55
GCS_Total_max	51.17
GCS_Total_min	51.17
GCS_Total_std	51.17
GCS_Total_mean	51.17
MBP_min	43.43
MBP_std	43.43
MBP_mean	43.43
MBP_max	43.43

Conclusões e observações do gráfico:

A análise dos valores em falta mostra que a feature matrix apresenta 932 744 valores nulos num total de 3 366 249 células preditivas, correspondendo a 27.71% de missing values. Este valor é significativo, mas esperado em dados clínicos reais de UCI, onde nem todos os sinais são medidos em todas as estadias nem com a mesma frequência.

Os valores em falta concentram-se sobretudo nas variáveis associadas ao Glasgow Coma Scale, nomeadamente 'GCS_Motor_Response', 'GCS_Verbal_Response', 'GCS_Eye_Opening' e 'GCS_Total'. Este padrão é clinicamente plausível, uma vez que os registos neurológicos são recolhidos de forma menos contínua do que sinais vitais como frequência cardíaca, SpO₂ ou frequência respiratória.

Nesta versão final da feature matrix, as features de contagem ('*_count') foram tratadas de forma semântica: quando um determinado sinal não foi medido numa estadia, o número de medições foi definido como 0. Assim, os nulos que permanecem dizem respeito sobretudo a estatísticas como média, mínimo, máximo e desvio-padrão, que não podem ser calculadas quando não existe qualquer medição desse sinal.


Os valores em falta não foram imputados nesta fase, de forma a evitar data leakage. A imputação será realizada apenas na Fase 2, dentro da pipeline de Machine Learning e depois da separação entre treino e teste. Esta decisão garante que estatísticas calculadas a partir do conjunto de teste não influenciam o treino dos modelos.

Assim, a estratégia mais adequada para a fase seguinte será aplicar imputação pela mediana às variáveis numéricas e acrescentar indicadores binários de ausência de medição. Esta abordagem permite preservar todas as estadias na análise e, ao mesmo tempo, explorar a possibilidade de a própria ausência de registo conter informação clínica relevante.

Matriz de Correlação entre Sinais Clínicos

A matriz de correlação de Spearman entre as features _mean revelou que a maioria dos sinais apresenta correlações fracas a moderadas. As correlações mais elevadas surgem entre as componentes do GCS ($r \approx 0.82$) e entre as variáveis de pressão arterial (SBP, DBP e MBP), o que é fisiologicamente esperado.

Matriz de Correlação



Conclusões e observações do gráfico:

A matriz de correlação de Spearman mostra que a maioria dos sinais clínicos apresenta correlações fracas ou moderadas entre si. Isto indica que as variáveis selecionadas não são totalmente redundantes e que cada grupo de sinais pode contribuir com informação fisiológica diferente para a modelação.

As correlações mais fortes surgem entre as componentes do Glasgow Coma Scale, nomeadamente entre 'GCS Eye Opening', 'GCS Motor Response' e 'GCS Verbal Response', com valores próximos de 0.82. Este resultado é esperado, uma vez que estas variáveis pertencem ao mesmo sistema de avaliação neurológica e tendem a variar de forma relacionada.

Também se observam correlações positivas moderadas entre as variáveis de pressão arterial, como 'DBP', 'SBP' e 'MBP'. Esta associação é fisiologicamente coerente, dado que estas medidas representam diferentes componentes do estado cardiovascular do paciente.


Fora destes grupos, as correlações são geralmente baixas, sugerindo que sinais como frequência cardíaca, frequência respiratória, temperatura e SpO₂ captam dimensões clínicas distintas. Por isso, não se justifica remover variáveis nesta fase apenas com base na correlação.

A decisão de manter estas features é adequada para a Fase 2, onde a relevância de cada variável será avaliada através dos modelos preditivos, da validação cruzada e da análise de importância das features.

Correlação entre Features e LOS_DIAS

A análise de correlação de Spearman entre cada feature e o LOS mostrou que as variáveis de contagem (número de medições) são as mais correlacionadas com estadias mais longas. A feature `Heart_Rate_count` apresentou a maior correlação positiva ($\rho = 0.416$), sugerindo que a intensidade de monitorização é um bom proxy da complexidade clínica.

Correlação Features vs. LOS_DIAS



Conclusões e observações do gráfico:

A análise de correlação de Spearman entre as features e o 'LOS_DIAS' mostra que nenhuma variável individual apresenta uma associação extremamente forte com o tempo de internamento. Isto indica que o LOS na UCI é um fenómeno multifatorial, que depende da combinação de vários sinais clínicos e demográficos, e não de uma única variável isolada.

As correlações positivas mais relevantes surgem nas features de contagem, especialmente 'Heart_Rate_count' ($\rho = 0.416$), 'SpO₂_count' ($\rho = 0.299$) e 'Respiratory_Rate_count' ($\rho = 0.274$). Este padrão sugere que estadias mais longas tendem a estar associadas a maior intensidade de monitorização clínica logo nas primeiras 24 horas de internamento.

Por outro lado, as correlações negativas mais fortes estão associadas às variáveis do Glasgow Coma Scale, como 'GCS_Total_max', 'GCS_Total_mean' e 'GCS_Verbal_Response_mean'. Como valores mais elevados de GCS indicam melhor estado neurológico, esta associação negativa é clinicamente coerente: pacientes com melhor avaliação neurológica inicial tendem, em média, a apresentar estadias mais curtas.

O heatmap confirma ainda que variáveis demográficas como `IDADE` e `GENDER\_BIN` apresentam correlações fracas com o `LOS\_DIAS`, sugerindo que, isoladamente, têm poder explicativo limitado. Ainda assim, estas variáveis devem ser mantidas na matriz preditiva, uma vez que podem contribuir em combinação com os restantes sinais clínicos.

Assim, esta análise reforça a necessidade de utilizar modelos multivariados na Fase 2. A seleção final e a relevância das features deverão ser avaliadas através de validação cruzada, desempenho preditivo e análise de importância das variáveis.

2.9 Encerramento e Checkpoint da Fase 1

A Fase 1 foi concluída com a exportação da feature matrix `df_features` em formato Parquet para o Google Drive. Este checkpoint garante a reprodutibilidade e evita o reprocessamento completo nas fases seguintes.

Etapa	Estratégia	Impacto
Extração inicial	Filtragem por ITEMID no BigQuery	Reduziu CHARTEVENTS de >330M para ~16.6M registos
Cruzamento relacional	JOINS executados no BigQuery	Evitou OOM no Colab
Limpeza temporal	Operações vetorizadas em pandas	Eficiência sem loops linha-a-linha
Filtragem janela 24h	Máscara booleana sobre <code>df_clean</code>	Redução de 16.6M para 8.2M registos
Agregação wide	<code>groupby + agg + unstack</code>	Transformação long - wide em formato final

3. Fase 2 : Pré-processamento, Modelação e Validação

3.1 Validação Estrutural e Definição de Features

A Fase 2 parte diretamente do ficheiro `df_features_fase1.parquet`. A validação confirmou 59 057 estadias, sem duplicados em `ICUSTAY_ID`. Foram identificados 8 271 pacientes com mais do que uma estadia, reforçando a necessidade de separação por `SUBJECT_ID` no split.

Elemento	Descrição	Dimensão
X (features)	57 variáveis preditivas clínicas e demográficas	59 057 × 57
y (target)	LOS_DIAS - tempo de internamento em dias	59 057
groups	SUBJECT_ID -agrupamento para split	44 940 únicos

3.2 Split Treino/Teste por Paciente

Para prevenir data leakage entre estadias do mesmo paciente, o split foi realizado com `GroupShuffleSplit` usando `SUBJECT_ID` como variável de agrupamento (`test_size = 20%`).

Conjunto	Estadias	Pacientes	Sobreposição SUBJECT_ID
Treino	~47 200	~35 950	0 (validado)
Teste	~11 857	~8 990	0 (validado)

A distribuição do `LOS_DIAS` é estatisticamente semelhante entre treino e teste, confirmando a qualidade do split. Foi ainda criado um conjunto de validação interno dentro do treino (`GroupShuffleSplit`, 20% do treino) para comparação de modelos candidatos sem tocar no conjunto de teste.

3.3 Pipeline de Pré-processamento

Foram definidas duas pipelines para garantir que os parâmetros de imputação são aprendidos apenas no treino:

Pipeline	Passos	Para Que Modelos
Linear	<code>SimpleImputer (mediana) + MissingIndicator + StandardScaler</code>	<code>LinearRegression</code> , <code>Ridge</code> , <code>ElasticNet</code>
Árvores	<code>SimpleImputer (mediana) + MissingIndicator</code>	<code>RandomForest</code> , <code>XGBoost</code> , <code>LightGBM</code> , <code>HistGBM</code>

A opção `add_indicator=True` no `SimpleImputer` cria 44 variáveis indicadoras de missingness, aumentando o número de features de 57 para 101. Esta decisão é clinicamente relevante: a ausência de medição na UCI pode ser informativa (ex: doentes sem registo de GCS têm perfil clínico diferente).

3.4 Modelos Lineares: Baseline Supervisionado

Antes dos modelos lineares, foi definido um baseline simples: prever sempre a mediana do LOS no treino (~ 2.14 dias). Este baseline obteve $MAE \approx 3.75$ dias no conjunto de teste - valor de referência mínima.

Foram testados três modelos lineares com target original e com target transformado $\log_{1p}(\text{LOS_DIAS})$:

- LinearRegression: modelo linear sem regularização.
- Ridge: regularização L2.
- ElasticNet: combinação L1 + L2.

Conclusão


O melhor modelo linear foi o ElasticNet com target $\log_{1p}$, obtendo $MAE \approx 3.49$ dias. A melhoria face ao baseline é modesta, sugerindo que as relações entre as features e o LOS não são predominantemente lineares.

3.5 Modelos Baseados em Árvores e Gradient Boosting

Foram testados quatro modelos não lineares:

- Random Forest ($n_estimators=120$, $max_depth=18$)
- HistGradientBoosting (scikit-learn nativo, suporte nativo a missing values)
- XGBoost (com target $\log_{1p}$)
- LightGBM (com target $\log_{1p}$)

Comparação Visual dos Modelos Candidatos



Conclusões e observações do gráfico:

A comparação dos modelos pelo 'MAE' no conjunto de validação interno mostra que os modelos supervisionados conseguem melhorar o baseline baseado na mediana do treino. O baseline apresenta um erro superior ao dos melhores modelos, confirmando que as features clínicas e demográficas extraídas na Fase 1 contêm informação útil para prever o 'LOS_DIAS'.

Os melhores resultados são obtidos pelos modelos baseados em árvores e métodos de boosting, especialmente 'LightGBM - log1p', 'XGBoost - log1p' e 'HistGradientBoosting - log1p', que apresentam valores de MAE muito próximos entre si. Isto sugere que a transformação logarítmica do target ajuda a lidar com a forte assimetria do 'LOS_DIAS', reduzindo o impacto das estadias extremamente longas.

Os modelos lineares apresentam desempenho menos competitivo, sobretudo nas versões com 'log1p', o que indica que a relação entre os sinais clínicos das primeiras 24 horas e o tempo de internamento não é puramente linear. Assim, modelos mais flexíveis conseguem captar melhor padrões não lineares presentes nos dados.

Com base nesta comparação, os modelos de boosting foram considerados os candidatos mais promissores para a etapa seguinte. O 'LightGBM' com target transformado por 'log1p(LOS_DIAS)' destacou-se como a melhor opção nesta validação interna, sendo posteriormente avaliado com validação cruzada e afinação de hiperparâmetros.

Conclusão

O melhor modelo foi o XGBoost com $\log_{1p}(\text{LOS_DIAS})$ (MAE ≈ 3.108 dias), seguido de perto pelo LightGBM (MAE ≈ 3.111 dias). Ambos representam uma melhoria substancial face aos modelos lineares e ao baseline.

3.6 Validação Cruzada com GroupKFold

Os melhores modelos candidatos foram avaliados com validação cruzada GroupKFold (5 folds), mantendo a separação por SUBJECT_ID em cada fold. Esta avaliação fornece uma estimativa mais robusta do desempenho.

Modelo	Target	MAE Médio (CV)	Desvio-Padrão
LightGBM	$\log_{1p}(\text{LOS_DIAS})$	3.148 dias	± 0.095
XGBoost	$\log_{1p}(\text{LOS_DIAS})$	~ 3.15 dias	$\pm \sim 0.10$
HistGradientBoosting	$\log_{1p}(\text{LOS_DIAS})$	~ 3.19 dias	$\pm \sim 0.10$
ElasticNet	$\log_{1p}(\text{LOS_DIAS})$	~ 3.49 dias	$\pm \sim 0.11$

Conclusão

O LightGBM com $\log_{1p}$ foi selecionado como melhor modelo com base na validação cruzada, combinando MAE mais baixo e baixo desvio-padrão entre folds.

3.7 Afinação de Hiperparâmetros

Foi realizada uma pesquisa moderada de hiperparâmetros para o LightGBM com GroupKFold (3 folds, 16 combinações = 48 treinos totais). A melhor configuração encontrada:

Hiperparâmetro	Valor Ótimo
learning_rate	0.03
n_estimators	350
num_leaves	63 (ou 64)
min_child_samples	40

3.8 Avaliação Final e Análise dos Erros

O modelo final foi treinado no conjunto de treino completo (X_{train}) e avaliado no conjunto de teste reservado:


Métrica	Modelo Final (LightGBM)	Baseline (Mediana)	Melhoria
MAE	~3.107 dias	~3.75 dias	17.10%
RMSE	8.4321	10.1507	16.93%
R^2	0.2530	-0.0826	--
MedianAE	0.9907	1.1695	--

Análise dos Erros por Grupo de LOS

O desempenho do modelo não é uniforme: é melhor em estadias curtas e moderadas, e piora progressivamente em estadias muito longas.

Grupo de LOS	MAE Aproximado
$LOS < 1$ dia	~0.67 dias
$1 \leq LOS < 2$ dias	~1.21 dias
$2 \leq LOS < 7$ dias	~2.5 dias
$LOS \geq 7$ dias	Alta (subestimação sistemática)

Análise dos Erros do Modelo Final


**Conclusões e observações do gráfico:**

A análise do erro absoluto médio por grupo de 'LOS' mostra que o desempenho do modelo final varia bastante consoante a duração real da estadia. O 'LightGBM' apresenta erros baixos nas estadias curtas e moderadas, com MAE reduzido nos grupos '< 1 dia', '1-2 dias' e '2-7 dias'. Isto indica que o modelo consegue prever com maior precisão os casos mais frequentes da base de dados.

No entanto, à medida que o tempo real de internamento aumenta, o erro cresce de forma acentuada. O MAE sobe nos grupos '7-14 dias' e '14-30 dias', atingindo o valor mais elevado nas estadias '>= 30 dias'. Este comportamento mostra que o modelo tem dificuldade em lidar com internamentos muito prolongados.

Esta limitação é coerente com a distribuição assimétrica do 'LOS_DIAS': existem muitas estadias curtas e poucas estadias extremamente longas. Assim, o modelo aprende melhor os padrões dos casos mais comuns e apresenta menor capacidade de previsão nos extremos da distribuição.

Conclui-se que o modelo final é adequado para estimar estadias curtas e intermédias, mas deve ser interpretado com cautela em pacientes com internamentos muito prolongados.



Conclusões e observações do gráfico:

O gráfico de dispersão entre 'LOS' real e 'LOS' previsto confirma visualmente a limitação observada na análise por grupos. Para estadias curtas e moderadas, existe uma maior concentração de pontos próxima da zona esperada, indicando que o modelo consegue produzir previsões razoáveis para a maioria dos casos.

No entanto, à medida que o 'LOS' real aumenta, os pontos afastam-se da linha de previsão ideal. Em particular, para estadias longas, o modelo tende a prever valores inferiores aos reais, evidenciando uma subestimação sistemática dos internamentos prolongados.

Esta tendência mostra que, apesar da transformação $\log_{lp}(\text{LOS_DIAS})$ ajudar a estabilizar a aprendizagem e melhorar o desempenho global, o modelo continua a produzir previsões conservadoras nos casos extremos. Ou seja, consegue capturar o comportamento geral da população, mas não estima bem durações muito elevadas.

Assim, este gráfico reforça que a regressão direta do 'LOS_DIAS' tem utilidade prática para casos comuns, mas apresenta limitações importantes nos doentes com maior tempo de permanência. Esta observação justifica a reformulação do problema na Fase 3 como classificação de risco de estadia prolongada.


3.9 Interpretabilidade com Permutation Importance

A Permutation Importance foi calculada sobre 5 000 estadias do conjunto de teste, usando MAE como métrica. As features mais importantes:

Rank	Feature	Importância Média (aumento MAE)
1º	Heart_Rate_count	~0.63 dias

2º	SpO2_count	~0.30 dias
3º	Respiratory_Rate_count	~0.27 dias
4–6	Heart_Rate_mean, Heart_Rate_min, ...	~0.10–0.20 dias

Permutation Importance



Conclusões e observações do gráfico:

A análise de 'Permutation Importance' mostra que a variável mais relevante para o modelo final é 'Heart_Rate_count', com uma diferença clara face às restantes features. Isto indica que o número de medições de frequência cardíaca nas primeiras 24 horas tem grande peso na previsão do 'LOS_DIAS'. No entanto, esta variável deve ser interpretada com cuidado, pois não representa diretamente o valor fisiológico da frequência cardíaca, mas sim a intensidade de monitorização do paciente.

Também surgem como importantes várias estatísticas associadas à frequência cardíaca, como 'Heart_Rate_min', 'Heart_Rate_mean', 'Heart_Rate_std' e 'Heart_Rate_max'. Isto mostra que o modelo utiliza tanto a quantidade de medições como o comportamento fisiológico da frequência cardíaca para estimar o tempo de internamento.

As variáveis relacionadas com o Glasgow Coma Scale também aparecem entre as mais relevantes, especialmente 'GCS_Total_max', 'GCS_Total_mean', 'GCS_Total_std' e 'GCS_Verbal_Response_mean'. Este resultado é clinicamente coerente, uma vez que o estado neurológico do paciente pode estar associado à gravidade do caso e à duração da permanência na UCI.

A variável `IDADE` também contribui para o modelo, embora com menor importância do que as features ligadas à frequência cardíaca e ao GCS. Isto sugere que a idade contém informação útil, mas não domina a previsão.

Em conjunto, estes resultados indicam que o modelo final se apoia sobretudo em três dimensões: intensidade de monitorização, sinais cardiovasculares e estado neurológico. Ainda assim, a importância das features deve ser interpretada como associação preditiva e não como causalidade. Uma variável ser importante para o modelo não significa que seja a causa direta de uma estadia mais longa.


Conclusão

As features de contagem (intensidade de monitorização) são as mais preditivas para o LOS, sugerindo que estadias mais longas tendem a ter maior frequência de registos clínicos - um proxy de complexidade clínica.

3.10 Análise de Sensibilidade e Conclusão da Fase 2

A análise de sensibilidade avaliou o desempenho do modelo em subconjuntos do teste: com e sem estadias muito curtas, e apenas estadias longas. O modelo mantém uma melhoria face ao baseline em todos os subconjuntos, mas a limitação em estadias muito longas (>7 dias) é evidente.

Análise de Sensibilidade por Subconjunto



Conclusões e observações do gráfico:

A análise de sensibilidade confirma que o `LightGBM` final melhora o baseline em todos os subconjuntos avaliados. No conjunto de teste completo, o modelo reduz o MAE face à previsão constante baseada na mediana, mostrando que acrescenta capacidade preditiva real em relação a uma abordagem simples.

Nas estadias curtas e moderadas, o modelo apresenta ganhos mais claros. Em particular, no subconjunto 'LOS < 24 horas', a redução do MAE é bastante expressiva, indicando que o modelo consegue distinguir melhor os casos de permanência curta do que o baseline. Também nos subconjuntos 'LOS >= 1 hora', 'LOS >= 6 horas' e 'LOS >= 24 horas', o modelo mantém desempenho superior ao baseline.

Contudo, nas estadias longas, apesar de continuar a melhorar o baseline, os erros absolutos permanecem elevados. Isto é particularmente evidente nos grupos 'LOS >= 7 dias' e 'LOS >= 30 dias', onde o MAE continua muito alto mesmo após a aplicação do modelo final. Esta limitação mostra que os internamentos prolongados são os casos mais difíceis de prever.

Assim, a análise de sensibilidade reforça a conclusão de que o modelo é útil e robusto para a maioria das estadias, especialmente curtas e intermédias, mas apresenta limitações importantes nos casos extremos. Esta dificuldade em prever estadias muito prolongadas justifica a reformulação do problema na Fase 3 como uma tarefa de classificação de risco.

Conclusão

A Fase 2 demonstrou que é possível prever o LOS de forma útil a partir de apenas 24 horas de dados clínicos, com uma melhoria de ~17% face ao baseline. A limitação nas estadias muito prolongadas motivou a Fase 3: reformulação como problema de classificação de risco.

4. Fase 3 : Estratificação de Risco por Janelas Temporais

4.1 Motivação e Objetivos

A Fase 3 surgiu diretamente das limitações observadas na Fase 2: a regressão, apesar de melhorar o baseline, revelou dificuldade sistemática em prever estadias muito prolongadas. Em vez de estimar o número exacto de dias, a Fase 3 reformula o problema: identificar antecipadamente se um doente terá uma estadia prolongada (classificação binária).

Adicionalmente, a Fase 3 estende a análise a quatro janelas temporais distintas (6h, 12h, 24h, 48h), investigando o compromisso entre precocidade e desempenho preditivo.

Parâmetro	Valores
Janelas temporais	6h, 12h, 24h, 48h
Targets binários	LOS_LONG_7 (≥ 7 dias), LOS_LONG_14 (≥ 14 dias), LOS_LONG_30 (≥ 30 dias)
Target principal	LOS_LONG_7 (prevalência ~16.41%)
Métrica principal	AUPRC (adequada a classes desbalanceadas)

4.2 Criação das Matrizes por Janela Temporal


Para cada janela, foi extraída uma nova matriz de features a partir dos dados longitudinais do MIMIC-III, mantendo a mesma coorte base (59 057 estadias, 44 940 pacientes) validada na Fase 1. Apenas as variáveis demográficas e o LOS foram partilhados entre janelas; as features clínicas foram recalculadas para cada intervalo temporal.

Janela	Medições Médias/Estadia	Missing Values (%)
6h	~40.7	~30.66%
12h	~80	~28%
24h	~138.8	27.71%
48h	~224.8	~25%

4.3 Targets Binários de Estadia Prolongada

Target	Limiar	Positivos (treino)	Prevalência	Papel
LOS_LONG_7	LOS ≥ 7 dias	~7 866	~16.60%	Principal
LOS_LONG_14	LOS ≥ 14 dias	~3 558	~7.50%	Secundário
LOS_LONG_30	LOS ≥ 30 dias	~735	~1.55%	Exploratório

Distribuição dos Targets Binários

**Conclusões e observações do gráfico:**

O gráfico mostra que os três targets binários apresentam diferentes níveis de desbalanceamento. O target 'LOS_LONG_7' é o menos raro, com a maior percentagem de casos positivos, sendo por isso escolhido como target principal da Fase 3. Este limiar permite identificar estadias prolongadas mantendo uma quantidade suficiente de exemplos positivos para treinar e avaliar os modelos.

À medida que o limiar aumenta, a prevalência da classe positiva diminui de forma acentuada. O target 'LOS_LONG_14' representa um problema mais difícil, com menor número de casos positivos, enquanto 'LOS_LONG_30' corresponde a um cenário muito raro e altamente desbalanceado.

Esta diferença justifica a escolha de métricas adequadas a classes desbalanceadas, como a 'AUPRC', além de métricas como 'precision', 'recall' e 'F1-score'. A utilização de 'accuracy' isoladamente seria insuficiente, uma vez que um modelo poderia obter bons valores apenas por prever a classe maioritária.

Assim, 'LOS_LONG_7' foi definido como o target principal por representar o melhor compromisso entre relevância clínica e viabilidade estatística, enquanto 'LOS_LONG_14' e 'LOS_LONG_30' foram mantidos como targets secundário e exploratório.

4.4 Treino Inicial dos Modelos de Classificação


O split único por SUBJECT_ID (GroupShuffleSplit, 80/20) foi aplicado de forma idêntica a todas as janelas temporais, garantindo comparabilidade. Para selecionar modelos sem usar o conjunto de teste, foi criado um split interno adicional dentro do treino.

Foram testados modelos de classificação com características distintas:

- Logistic Regression (com e sem regularização)

- Random Forest Classifier
- HistGradientBoostingClassifier
- LightGBM Classifier

Comparação dos Modelos por Janela



Conclusões e observações dos gráficos:

A análise conjunta da AUPRC e do recall mostra que o desempenho dos modelos melhora de forma consistente com o aumento da janela temporal. A janela de 48h apresenta os melhores resultados, indicando que a acumulação de mais medições clínicas aumenta a capacidade de identificar estadias prolongadas.

Os modelos baseados em árvores e boosting, especialmente `HistGradientBoosting`, `LightGBM` e `Random Forest`, superam a Regressão Logística, sugerindo que o problema envolve relações não lineares entre as variáveis clínicas e o risco de internamento prolongado.


Apesar de a janela de 48h ser superior em desempenho, esta escolha implica uma menor precocidade da previsão. Assim, os resultados evidenciam o compromisso central da Fase 3: janelas mais longas melhoram a performance, mas reduzem a utilidade operacional de uma previsão verdadeiramente antecipada.

4.5 Comparação Global entre Janelas Temporais

A análise comparativa respondeu à questão central da Fase 3: o ganho de desempenho com janelas mais longas compensa a perda de precocidade?

Janela	Melhor (LOS_LONG_7) AUPRC	vs. Baseline	Ganho Marginal vs. 24h
6h	0.4835	+3.09× baseline	--
12h	~0.53	+~3.4× baseline	--
24h	0.5667	+3.62× baseline	Referência
48h	0.6614	+4.23× baseline	+0.0947

Evolução da AUPRC por Janela



Conclusões e observações dos gráficos:

A comparação do melhor valor de AUPRC por janela temporal mostra uma tendência clara e consistente: o desempenho melhora à medida que aumenta a quantidade de informação clínica disponível. Tanto para o target principal 'LOS_LONG_7' como para o target secundário 'LOS_LONG_14', a melhor AUPRC cresce progressivamente das 6h até às 48h.

No caso de 'LOS_LONG_7', a AUPRC sobe de aproximadamente 0.48 na janela de 6h para cerca de 0.66 na janela de 48h. Para 'LOS_LONG_14', o mesmo padrão repete-se, com a AUPRC a aumentar de cerca de 0.33 para aproximadamente 0.44. Estes resultados mostram que a inclusão de mais horas de monitorização melhora a capacidade dos modelos para distinguir pacientes com risco de estadia prolongada.

Observa-se também que o target 'LOS_LONG_7' apresenta desempenho superior ao 'LOS_LONG_14' em todas as janelas. Isto é esperado, uma vez que 'LOS_LONG_14' é mais raro e, por isso, constitui um problema de classificação mais difícil e mais desbalanceado.

Apesar de a janela de 48h apresentar o melhor desempenho técnico, esta escolha implica menor precocidade da previsão. Assim, o gráfico evidencia o principal trade-off da Fase 3: janelas mais longas melhoram a qualidade preditiva, mas reduzem a antecipação clínica. Neste contexto, a janela de 24h continua a ser uma alternativa relevante por oferecer um equilíbrio entre desempenho e utilidade prática, enquanto a de 48h representa a melhor opção puramente em termos de performance.

4.6 Afinação de Threshold e Avaliação Final no Conjunto de Teste



A configuração principal selecionada foi o HistGradientBoostingClassifier, janela de 48h, target LOS_LONG_7. A afinação do threshold (padrão = 0.5) mostrou que o threshold ótimo pelo critério de F1-score é 0.70.

Threshold	Precision	Recall	F1-Score	Balanced Accuracy
0.50 (padrão)	~0.49	~0.82	~0.61	~0.82
0.70 (ótimo)	~0.61	~0.69	~0.65	~0.80

Resultados Finais no Conjunto de Teste

Métrica	Configuração 48h	Configuração 24h (referência)
AUPRC	0.6105	~0.52
AUROC	0.8961	~0.85
F1-Score	0.6167	~0.56
Recall	0.6743	~0.78
Precision	0.5681	~0.44
Balanced Accuracy	0.7897	~0.79
Verdadeiros Positivos	1 230	--
Falsos Positivos	935	--
Falsos Negativos	594	--

Avaliação Final da Classificação

**Conclusões e observações dos gráficos:**

A avaliação final no conjunto de teste mostra que a configuração `HistGradientBoostingClassifier` com janela de 48h e target `LOS\_LONG\_7` apresenta boa capacidade de estratificação de risco. A curva Precision-Recall

confirma que o modelo consegue identificar estadias prolongadas de forma útil num contexto de classes desbalanceadas, atingindo uma AUPRC de 0.6105, valor bastante superior à prevalência da classe positiva.

A curva Precision-Recall evidencia também o compromisso entre `precision` e `recall`: quando o modelo é mais seletivo, a precision é mais elevada, mas identifica menos casos positivos; quando se aumenta o recall, o modelo deteta mais estadias prolongadas, mas também aumenta o número de falsos positivos. Este comportamento é esperado e justifica a afinação posterior do threshold.

A curva ROC reforça a boa capacidade discriminativa global do modelo. O valor de AUROC de 0.8961 mostra que o modelo distingue eficazmente estadias prolongadas de não prolongadas, encontrando-se claramente acima da linha de classificação aleatória.

Em conjunto, as duas curvas confirmam que o modelo final generaliza bem para dados não vistos. A Precision-Recall é especialmente relevante por avaliar melhor o desempenho sobre a classe positiva, enquanto a ROC mostra a separação global entre classes. Assim, a configuração final de 48h apresenta desempenho robusto para sinalizar pacientes com maior risco de estadia prolongada na UCI.

Matriz de confusão

	Pred_0	Pred_1
Real_1	8 911	935
Real_0	594	1 230

Conclusões e observações dos gráficos:

A matriz de confusão mostra que o modelo final identificou corretamente 1 230 estadias prolongadas ('TP') e 8 911 estadias não prolongadas ('TN'). Estes valores indicam uma boa capacidade global de separação entre pacientes com e sem risco de estadia superior a 7 dias.

No entanto, o modelo também produziu 935 falsos positivos, ou seja, pacientes sinalizados como alto risco que não tiveram estadia prolongada, e 594 falsos negativos, correspondentes a pacientes com estadia prolongada que não foram corretamente identificados. Em contexto clínico, os falsos negativos são particularmente relevantes, pois representam casos de risco que poderiam não ser antecipados pelo sistema.


Com o threshold ajustado para 0.70, o modelo torna-se mais seletivo: reduz falsos positivos face a thresholds mais baixos, mas aceita alguma perda de recall. Assim, esta matriz confirma o compromisso escolhido entre identificar um número relevante de estadias prolongadas e evitar um excesso de alertas falsos.

4.7 Interpretabilidade e Análise dos Pacientes de Maior Risco

Permutation Importance

A análise foi realizada com AUPRC como métrica. A feature mais importante foi Heart_Rate_count (importância ≈ 0.2861), confirmando o papel central da intensidade de monitorização. Seguem-se Heart_Rate_mean, Heart_Rate_min e variáveis demográficas como IDADE.

Permutation Importance Fase 3

**Conclusões e observações dos gráficos:**

A análise de 'Permutation Importance' mostra que a feature mais relevante para a classificação de risco é 'Heart_Rate_count', com uma importância claramente superior às restantes variáveis. Isto significa que, quando esta feature é permutada, a AUPRC do modelo diminui de forma acentuada, indicando que o número de medições de frequência cardíaca nas primeiras 48 horas é altamente informativo para prever estadias prolongadas.

No entanto, esta variável deve ser interpretada com cautela, uma vez que representa a frequência de monitorização e não apenas o valor fisiológico da frequência cardíaca. Assim, 'Heart_Rate_count' pode estar a funcionar como uma proxy da intensidade de vigilância clínica, da gravidade do paciente ou da complexidade do episódio na UCI.

Além da frequência cardíaca, surgem também como relevantes variáveis associadas ao Glasgow Coma Scale, como 'GCS_Total_mean', 'GCS_Verbal_Response_mean', 'GCS_Total_max' e 'GCS_Total_std'. Este resultado é clinicamente coerente, pois o estado neurológico inicial pode estar relacionado com a gravidade do caso e com a probabilidade de uma estadia prolongada.


A variável 'IDADE' também aparece entre as features mais importantes, reforçando que fatores demográficos contribuem para a estratificação de risco, embora com menor peso do que as variáveis de monitorização cardíaca e neurológica.

Em conjunto, estes resultados indicam que o modelo final se apoia sobretudo em três dimensões: intensidade de monitorização, estado cardiovascular e estado neurológico. Ainda assim, a importância das features deve ser interpretada como associação preditiva e não como relação causal direta.

Análise por Decis de Risco

Quando as estadias são ordenadas por probabilidade de alto risco, observa-se um gradiente claro: a taxa real de LOS_LONG_7 sobe de quase zero nos decis mais baixos para 65.21% no decil de maior risco. O top 10% de maior risco apresenta uma taxa de 65.24% - um enriquecimento de $4.17\times$ face à prevalência global (15.63%).

Análise por Decis de Risco



Conclusões e observações dos gráficos:

A análise por decis de risco mostra que as probabilidades produzidas pelo modelo têm significado prático. À medida que o decil de risco previsto aumenta, a taxa real de estadia prolongada ('LOS_LONG_7') também aumenta de forma clara, indicando que o modelo consegue ordenar os pacientes de acordo com o risco.

Nos decis mais baixos, a percentagem real de estadias prolongadas é praticamente nula ou muito reduzida, o que mostra que o modelo identifica corretamente grupos de baixo risco. A partir dos decis superiores, especialmente no 9.º e 10.º decis, observa-se um aumento acentuado da taxa real de 'LOS_LONG_7'.

O decil de maior risco concentra cerca de 65% de estadias prolongadas, um valor muito superior à prevalência global no teste, que é aproximadamente 15.6%. Isto significa que o modelo consegue criar um grupo de alto risco substancialmente enriquecido em pacientes que efetivamente terão uma estadia superior a 7 dias.

Assim, esta análise confirma que o modelo não se limita a produzir uma classificação binária, mas também fornece uma ordenação útil de risco. Esta capacidade é relevante em contexto clínico, porque permite priorizar pacientes para monitorização, planeamento de recursos e eventual intervenção antecipada.

4.8 Comparação com a Regressão da Fase 2


As abordagens das Fases 2 e 3 são complementares e respondem a perguntas clínicas distintas:

Aspeto	Fase 2 (Regressão)	Fase 3 (Classificação)
Pergunta clínica	Quantos dias ficará o doente?	Este doente ficará >7 dias?
Output	LOS previsto em dias	Probabilidade de risco
Melhor modelo	LightGBM + log1p(LOS)	HistGBM + threshold 0.70
Métrica principal	MAE = 3.107 dias	AUPRC = 0.61, AUROC = 0.90
Limitação	Subestimação em LOS longo	Menos granular (binário)
Utilidade clínica	Planeamento de alta	Triagem e alocação de recursos

4.9 Precocidade vs. Desempenho - Discussão Final

A análise do trade-off entre precocidade e desempenho mostrou que já com apenas 6 horas de dados é possível obter sinais preditivos relevantes (AUPRC 0.48 para LOS_LONG_7). O desempenho aumenta progressivamente até às 48h, com um ganho marginal considerável entre 24h e 48h (+0.09 AUPRC).

Trade-off Precocidade vs. Desempenho



Conclusões e observações dos gráficos:

A análise do desempenho por janela temporal confirma o compromisso entre precocidade e capacidade preditiva. À medida que a janela aumenta de 6h para 48h, observa-se uma melhoria geral das métricas, especialmente da 'AUPRC', do 'F1-score' e do 'recall'. Isto indica que a acumulação de mais informação clínica ao longo do tempo permite ao modelo identificar melhor os pacientes com risco de estadia prolongada.

Mesmo com apenas 6h de dados, o modelo já apresenta sinal preditivo relevante, atingindo uma AUPRC superior ao baseline da prevalência da classe positiva. No entanto, as métricas melhoram de forma consistente nas janelas de 12h, 24h e 48h, mostrando que medições adicionais ajudam a reduzir incerteza e a captar melhor a evolução clínica inicial.

A janela de 48h apresenta o melhor desempenho global, com os valores mais elevados de `AUPRC`, `F1-score`, `recall` e `precision`. Esta configuração é, portanto, a melhor do ponto de vista técnico. Contudo, implica menor precocidade, uma vez que a previsão só é feita após dois dias de internamento.

A janela de 24h surge como uma alternativa relevante, porque mantém uma previsão mais precoce e ainda apresenta desempenho robusto. Assim, a escolha da janela depende do objetivo prático: se a prioridade for maximizar desempenho, a janela de 48h é superior; se a prioridade for antecipar a decisão clínica, a janela de 24h oferece um melhor equilíbrio entre precocidade e qualidade preditiva.

Conclusão

A janela de 24h representa o melhor equilíbrio prático: permite uma previsão suficientemente precoce (ainda no primeiro dia) com um desempenho robusto ($AUPRC \approx 0.57$, $AUROC \approx 0.85$). A janela de 48h é superior em desempenho, mas implica esperar mais tempo para tomar decisões clínicas.

4.10 Profiling Computacional e Discussão de Performance

Durante o desenvolvimento das fases de Machine Learning foi realizado profiling computacional para medir o tempo de execução das principais etapas do pipeline, identificar os blocos mais dispendiosos e discutir possíveis limitações de desempenho. Esta análise é relevante porque o projeto trabalha com uma matriz clínica de dimensão considerável, com 59 057 estadias UCI, múltiplas features agregadas e várias experiências de modelação, incluindo validação cruzada, afinação de hiperparâmetros e métodos de interpretabilidade.

Embora a Fase 1 tenha concentrado o maior desafio de engenharia de dados, devido ao processamento inicial da tabela CHARTEVENTS com mais de 330 milhões de registos, as Fases 2 e 3 concentraram o custo computacional associado ao treino e validação dos modelos. Por esse motivo, o profiling foi analisado sobretudo nas fases de regressão e classificação.

Profiling da Fase 2 :Regressão

Na Fase 2, o tempo total aproximado de execução foi de **697.18 segundos**, correspondente a cerca de **11.62 minutos**. Considerando apenas as etapas diretamente associadas à pipeline de Machine Learning, o tempo acumulado foi de aproximadamente **667.47 segundos**, ou **11.12 minutos**.

Etapa	Tempo aproximado
Afinação de hiperparâmetros do melhor modelo	252.35 s

Validação cruzada com GroupKFold	221.70 s
Permutation Importance	77.14 s
Treino inicial dos modelos de árvores e gradient boosting	62.01 s
Treino dos modelos lineares	42.07 s
Treino e avaliação final	8.15 s

A etapa mais pesada foi a **afinação de hiperparâmetros**, uma vez que implicou testar várias combinações do modelo LightGBM com validação cruzada. A segunda etapa mais custosa foi a **validação cruzada com GroupKFold**, que é computacionalmente mais exigente do que um split simples, mas necessária para garantir que estadias do mesmo paciente não aparecem simultaneamente em treino e validação.

A Permutation Importance também teve custo relevante, porque exige repetir a avaliação do modelo várias vezes, permutando cada variável para medir o seu impacto no desempenho. Apesar deste custo adicional, esta etapa foi mantida por ser importante para interpretar o modelo final e perceber quais as features mais relevantes para a previsão do LOS_DIAS.

Assim, na Fase 2, os principais custos computacionais estiveram associados às decisões que aumentam a robustez metodológica do trabalho: validação por grupos, tuning de hiperparâmetros e interpretabilidade.

Profiling da Fase 3 : Classificação

Na Fase 3, o tempo total medido pelas etapas registadas foi de aproximadamente **490.87 segundos**, ou **8.18 minutos**. O tempo total wall-clock foi muito próximo, cerca de **493.00 segundos**, ou **8.22 minutos**.

Etapa	Tempo aproximado	Percentagem do tempo medido
Treino inicial dos modelos	248.92 s	50.71%
Permutation Importance	151.65 s	30.89%
Avaliação final no conjunto de teste	17.87 s	3.64%
Criação dos targets binários	11.56 s	2.36%
Split único por SUBJECT_ID	7.49 s	1.53%
Afinação de threshold	6.88 s	1.40%
Validação das matrizes por janela	6.81 s	1.39%

Na Fase 3, a etapa mais dispendiosa foi o **treino inicial dos modelos**, representando cerca de metade do tempo medido. Este resultado é esperado, uma vez que foram avaliados vários modelos de classificação, diferentes janelas temporais e mais do que um target binário de estadia prolongada.

A segunda etapa mais pesada foi novamente a **Permutation Importance**, responsável por cerca de 30.89% do tempo total medido. Tal como na Fase 2, este custo resulta do facto de a técnica exigir várias reavaliações do modelo após permutar cada feature.

A criação dos targets binários, a validação das matrizes por janela e o split por SUBJECT_ID tiveram custos reduzidos quando comparados com o treino dos modelos. Isto indica que o principal gargalo computacional da Fase 3 não esteve na preparação dos dados, mas sim na comparação sistemática de modelos e na interpretação do modelo final.

Discussão dos Problemas de Performance

O principal problema de performance do projeto surgiu do volume inicial dos dados clínicos. A tabela CHARTEVENTS contém mais de 330 milhões de registos, tornando inviável o processamento local direto no Google Colab. Para mitigar este problema, a extração inicial foi feita no **BigQuery**, aplicando filtros por ITEMID, remoção de valores nulos críticos e junções relacionais antes de transferir os dados para o ambiente local. Esta decisão reduziu substancialmente o volume de dados processado em pandas e evitou erros de memória.

Nas fases de Machine Learning, o custo computacional foi dominado por três tipos de operações:

1. **Validação cruzada com separação por paciente**, necessária para evitar data leakage, mas mais lenta do que validações aleatórias simples.
2. **Afinação de hiperparâmetros**, especialmente em modelos de gradient boosting, que exigem múltiplos treinos.
3. **Interpretabilidade por Permutation Importance**, que aumenta o tempo de execução por requerer avaliações repetidas do modelo.

Apesar destes custos, os tempos totais foram aceitáveis para a dimensão do problema. A Fase 2 demorou cerca de 11.62 minutos e a Fase 3 cerca de 8.22 minutos, mostrando que a pipeline é executável em ambiente Google Colab sem necessidade de infraestrutura computacional especializada.

Estratégias Usadas para Melhorar a Eficiência

Foram adotadas várias decisões para controlar o custo computacional:

- utilização do BigQuery para processar a tabela CHARTEVENTS antes da extração local;
- exportação da feature matrix da Fase 1 em formato Parquet, evitando repetir a extração completa nas fases seguintes;
- uso de operações vetorizadas em pandas, em vez de loops linha-a-linha;
- separação entre treino, validação e teste por SUBJECT_ID, garantindo robustez sem duplicar desnecessariamente os dados;
- limitação da pesquisa de hiperparâmetros a uma grelha moderada;
- cálculo da Permutation Importance apenas sobre amostras ou subconjuntos controlados, reduzindo o custo de interpretação.

Conclusão da Análise de Performance

A análise de profiling mostra que o pipeline apresentou um custo computacional controlado. A Fase 1 exigiu decisões de engenharia de dados para lidar com o volume inicial do MIMIC-III, enquanto as Fases 2 e 3 concentraram o custo nas etapas de treino, validação, tuning e interpretabilidade.

A Fase 2 teve maior custo total devido à validação cruzada e à afinação do modelo de regressão, enquanto a Fase 3 teve custo concentrado no treino de múltiplos classificadores e na análise de importância das features.

Em ambos os casos, os tempos de execução foram compatíveis com um ambiente académico em Google Colab e justificam-se pelas garantias metodológicas adicionadas: prevenção de data leakage, comparação robusta de modelos e interpretação dos resultados.

5. Conclusão Geral

Este projeto demonstrou que é possível construir uma pipeline completa de Machine Learning clínico sobre dados reais de UCI, desde a extração de dados de grande escala até à interpretabilidade dos modelos, utilizando o MIMIC-III como fonte de dados.

Principais Contribuições

- Fase 1: construção de uma feature matrix clinicamente fundamentada para 59 057 estadias UCI, com seleção de sinais referenciados no SOFA, tratamento de artefactos do MIMIC-III e validação cuidadosa de cada etapa do pipeline.
- Fase 2: comparação sistemática de modelos de regressão com split anti-leakage por SUBJECT_ID, demonstrando uma melhoria de 17% face ao baseline e identificando as variáveis de intensidade de monitorização como as mais preditivas.
- Fase 3: reformulação como problema de classificação binária por janelas temporais, mostrando que é possível estratificar risco com AUROC ≈ 0.90 a partir das primeiras 6–48 horas de internamento.

Limitações e Trabalho Futuro

- A subestimação sistemática do LOS em estadias muito longas (>7 dias) manteve-se em ambas as abordagens. Estratégias como treino com amostras ponderadas ou modelos específicos para os extremos da distribuição poderiam mitigar este problema.
- A fragmentação do GCS entre sistemas CareVue e MetaVision poderia ser endereçada com a criação de uma variável derivada consolidada.
- A extensão a outras variáveis clínicas (diagnósticos, SOFA score, dados laboratoriais) poderia enriquecer a feature matrix e melhorar o desempenho preditivo.
- A validação externa em cohorts de outros hospitais seria necessária para confirmar a generalização dos modelos.

Questão de Investigação	Resposta
Qual a melhor janela temporal?	24h - melhor equilíbrio entre precocidade e cobertura (Fases 1 e 2). 48h - melhor desempenho preditivo (Fase 3).
Consegue-se prever o LOS a partir de 24h?	Sim. LightGBM obteve MAE ≈ 3.1 dias, melhoria de 17% face ao baseline.
É possível identificar risco precoce?	Sim. AUROC ≈ 0.90 com HistGBM + 48h de dados. Com 6h, AUROC ≈ 0.80 .
Quais os sinais mais preditivos?	Intensidade de monitorização (Heart_Rate_count, SpO2_count) e estado neurológico (GCS).

O conjunto das três fases constitui uma pipeline end-to-end de suporte à decisão clínica, capaz de estratificar o risco de estadia prolongada desde as primeiras horas de internamento na UCI.

6. Referências

1. Johnson, A. E. W., Pollard, T. J., Shen, L., Lehman, L. H., Feng, M., Ghassemi, M., Moody, B., Szolovits, P., Celi, L. A., & Mark, R. G. (2016). **MIMIC-III, a freely accessible critical care database**. *Scientific Data*, 3, 160035.
Link: <https://www.nature.com/articles/sdata201635>
2. Johnson, A., Pollard, T., & Mark, R. (2016). **MIMIC-III Clinical Database v1.4**. *PhysioNet*.
Link: <https://physionet.org/content/mimiciii/>
3. Goldberger, A. L., Amaral, L. A. N., Glass, L., Hausdorff, J. M., Ivanov, P. C., Mark, R. G., Mietus, J. E., Moody, G. B., Peng, C. K., & Stanley, H. E. (2000). **PhysioBank, PhysioToolkit, and PhysioNet: Components of a new research resource for complex physiologic signals**. *Circulation*, 101(23), e215–e220.
Link: <https://pubmed.ncbi.nlm.nih.gov/10851218/>
4. MIT Laboratory for Computational Physiology. **MIMIC-III Documentation: Tables**.
Link: <https://mimic.mit.edu/docs/III/tables/>
5. MIT Laboratory for Computational Physiology. **MIMIC-III Documentation: ICUSTAYS table**.
Link: <https://mimic.mit.edu/docs/III/tables/icustays.html>
6. MIT Laboratory for Computational Physiology. **MIMIC Code Repository**.
Link: <https://github.com/MIT-LCP/mimic-code>
7. MIT Laboratory for Computational Physiology. **vitals_first_day.sql — MIMIC-III concept query for vital signs**.
Link: https://github.com/MIT-LCP/mimic-code/blob/main/mimic-iii/concepts_postgres/firstday/vitals_first_day.sql
8. Johnson, A. E. W., Stone, D. J., Celi, L. A., & Pollard, T. J. (2018). **The MIMIC Code Repository: enabling reproducibility in critical care research**. *Journal of the American Medical Informatics Association*.
Link: <https://pmc.ncbi.nlm.nih.gov/articles/PMC6381763/>

9. Teasdale, G., & Jennett, B. (1974). **Assessment of coma and impaired consciousness: A practical scale.** *The Lancet*, 2(7872), 81–84.
Link: <https://pubmed.ncbi.nlm.nih.gov/4136544/>
10. Jain, S., & Iverson, L. M. **Glasgow Coma Scale.** *StatPearls / NCBI Bookshelf*.
Link: <https://www.ncbi.nlm.nih.gov/books/NBK513298/>
11. Knaus, W. A., Draper, E. A., Wagner, D. P., & Zimmerman, J. E. (1985). **APACHE II: A severity of disease classification system.** *Critical Care Medicine*.
Link: <https://pubmed.ncbi.nlm.nih.gov/3928249/>
12. Vincent, J. L., Moreno, R., Takala, J., Willatts, S., De Mendonça, A., Bruining, H., Reinhart, C. K., Suter, P. M., & Thijs, L. G. (1996). **The SOFA score to describe organ dysfunction/failure.** *Intensive Care Medicine*, 22, 707–710.
Link: <https://pubmed.ncbi.nlm.nih.gov/8844239/>
13. Google Cloud. **BigQuery documentation.**
Link: <https://cloud.google.com/bigquery>
14. Google Cloud SDK. **gcloud auth application-default login.**
Link: <https://docs.cloud.google.com/sdk/gcloud/reference/auth/application-default/login>
15. scikit-learn developers. **GroupShuffleSplit.**
Link: https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.GroupShuffleSplit.html
16. scikit-learn developers. **GroupKFold.**
Link: https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.GroupKFold.html
17. scikit-learn developers. **SimpleImputer.**
Link: <https://scikit-learn.org/stable/modules/generated/sklearn.impute.SimpleImputer.html>

18. scikit-learn developers. **Imputation of missing values.**
Link: <https://scikit-learn.org/stable/modules/impute.html>

19. scikit-learn developers. **HistGradientBoostingRegressor.**
Link: <https://scikit-learn.org/stable/modules/generated/sklearn.ensemble.HistGradientBoostingRegressor.html>

20. scikit-learn developers. **HistGradientBoostingClassifier.**
Link: <https://scikit-learn.org/stable/modules/generated/sklearn.ensemble.HistGradientBoostingClassifier.html>

21. scikit-learn developers. **Permutation Importance.**
Link: https://scikit-learn.org/stable/modules/generated/sklearn.inspection.permutation_importance.html

22. scikit-learn developers. **Precision-Recall and Average Precision.**
Link: https://scikit-learn.org/stable/auto_examples/model_selection/plot_precision_recall.html

23. scikit-learn developers. **average_precision_score.**
Link: https://scikit-learn.org/stable/modules/generated/sklearn.metrics.average_precision_score.html

24. scikit-learn developers. **balanced_accuracy_score.**
Link: https://scikit-learn.org/stable/modules/generated/sklearn.metrics.balanced_accuracy_score.html

25. scikit-learn developers. **roc_auc_score.**
Link: https://scikit-learn.org/stable/modules/generated/sklearn.metrics.roc_auc_score.html

26. LightGBM developers. **LightGBM Python API.**
Link: <https://lightgbm.readthedocs.io/en/latest/Python-API.html>

27. LightGBM developers. **LGBMRegressor**.

Link: <https://lightgbm.readthedocs.io/en/latest/pythonapi/lightgbm.LGBMRegressor.html>

28. XGBoost developers. **XGBoost Python API Reference**.

Link: https://xgboost.readthedocs.io/en/latest/python/python_api.html

29. MIT Laboratory for Computational Physiology. MIMIC-III Documentation:

Tables. <https://mimic.mit.edu/docs/III/tables/>